## 先端データ解析論 第2回レポート

# 電子情報学専攻 48-176403 石毛真修 2017年4月25日

### 大問 1.

 $y=rac{sin(\pi x)}{\pi x}+0.1x+0.2 imes random$  を ガウスカーネルモデル  $f_{ heta}(x)=\sum_{j=1}^n heta_j K(x_i,x_j)$  で近似し,更にそのハイパーパラメータである  $\lambda$  とカーネル関数の分散 h を,交差確認法を使って決定する.

#### リスト 1: Regression Part

```
import matplotlib.pyplot as plt
import numpy as np

def org.model(x):
    return np.sin(np.pi * x) / (np.pi * x) + 0.1 * x

def get.samples(x.samples, f):
    return f(x.samples) + 0.2* np.random.randn(len(x.samples))

def kern(x, c, h=0.2):
    norm = x - c
    return np.exp(- norm**2 / (2 * (h**2)))

kerns = np.vectorize(kern)
def kern.matrix(x.samples, h=0.2):
    return np.array([kerns(xi, x.samples, h) for xi in x.samples])

def estimate.theta(samples.x, samples.y, lamb=1, h=0.2):
    K = kern.matrix(samples.x, h)
    Q = np. linalg.inv(np.matmul(K, K) + lamb * np.eye(len(samples.x)))
    p = np.matmul(pp.transpose(K), samples.y)
    return np.matmul(p, p)

def kern.model.gen(x.samples, y.samples, lamb=1, h=0.2):
    est.theta = estimate.theta(x.samples, y.samples, lamb, h)
    def .model(x):
        return np.dot(est.theta, kerns(x, x.samples, h))
    v.model = np.vectorize(.model)

        return v.model

        np.random.seed()
        x.min, x.max = -3, 3
        n = 50
        N = 1000
        x = np.linapace(x.min, x.max, n)
        Y = org.model(x)
    # -y = get.samples(x, org.model)
    lamb = 0.1
    lamb = 0.7
    est.model = kern.model.gen(x, -y, lamb, h)
    Y = est.model(X)
    plt.scatter(x, -y)
    plt.plot(x, y, 'r-', X, Y, 'b-')
    plt.show()
```

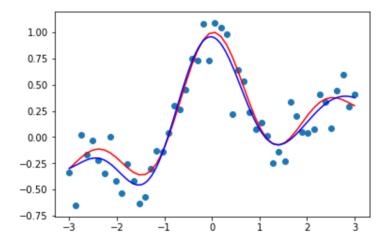


図 1: 曲線  $y = \frac{sin(\pi x)}{\pi x} + 0.1x$  (赤) と  $\lambda = 0.1$ , h = 0.7 のときの回帰曲線 (青).

リスト 2: Cross Validation and Grid Search

このコードを実行することにより、 $\lambda=0.1$ 、h=0.78 のとき平均誤差が 0.0374637682683 となるような回帰曲線が得られた。

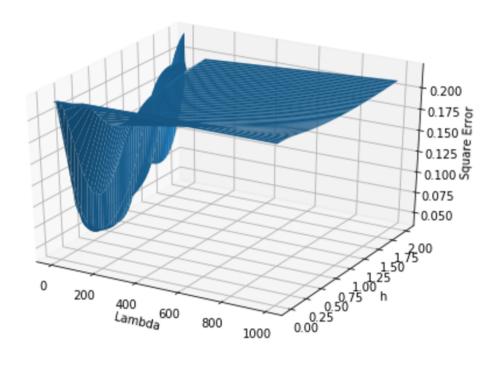


図 2: グリッドサーチの結果

## 大問 2.

線形モデル  $f_{\theta} = \sum_{j=1}^b \theta_j \phi_j(\mathbf{x})$  を用いた  $l_2$ -正則化回帰に対するひとつ抜き交差確認による二乗誤差が、次のようになることを示す.

$$\frac{1}{n} \|\tilde{\mathbf{H}}^{-1} \mathbf{H} \mathbf{y}\|^2$$

### 導出

標本  $(\mathbf{x}_i, y_i)$  を除いて学習したパラメータ  $\hat{\theta}_i$  は次のように表される.

$$\hat{\theta_i} = (\mathbf{\Phi}_i^{\mathrm{T}} \mathbf{\Phi}_i + \lambda \mathbf{I})^{-1} \mathbf{\Phi}_i^{\mathrm{T}} \mathbf{y}_i = \mathbf{U}_i^{-1} \mathbf{\Phi}_i^{\mathrm{T}} \mathbf{y}_i$$

$$\begin{aligned} \mathbf{U}_i &= \mathbf{\Phi}_i^{\mathrm{T}} \mathbf{\Phi}_i + \lambda \mathbf{I} \\ &= \mathbf{\Phi}^{\mathrm{T}} \mathbf{\Phi} - \phi_i \boldsymbol{\phi}_i^{\mathrm{T}} + \lambda \mathbf{I} \\ &= (\mathbf{\Phi}^{\mathrm{T}} \mathbf{\Phi} + \lambda \mathbf{I}) - \phi_i \boldsymbol{\phi}_i^{\mathrm{T}} \end{aligned}$$

であるので,

$$\begin{split} \mathbf{U}_{i}^{-1} &= \{(\mathbf{\Phi}^{\mathrm{T}}\mathbf{\Phi} + \lambda \mathbf{I}) - \phi_{i}\phi_{i}^{\mathrm{T}}\}^{-1} \\ &= (\mathbf{\Phi}^{\mathrm{T}}\mathbf{\Phi} + \lambda \mathbf{I})^{-1} + \frac{(\mathbf{\Phi}^{\mathrm{T}}\mathbf{\Phi} + \lambda \mathbf{I})^{-1}\phi_{i}\phi_{i}^{\mathrm{T}}(\mathbf{\Phi}^{\mathrm{T}}\mathbf{\Phi} + \lambda \mathbf{I})^{-1}}{1 - \phi_{i}^{\mathrm{T}}(\mathbf{\Phi}^{\mathrm{T}}\mathbf{\Phi} + \lambda \mathbf{I})^{-1}\phi_{i}} \\ &= \mathbf{U}^{-1} + \frac{\mathbf{U}^{-1}\phi_{i}\phi_{i}^{\mathrm{T}}\mathbf{U}^{-1}}{\gamma_{i}} \end{split}$$

ただし,

$$\gamma_i = 1 - \phi_i^{\mathrm{T}} (\mathbf{\Phi}^{\mathrm{T}} \mathbf{\Phi} + \lambda \mathbf{I})^{-1} \phi_i$$

以上から,

$$\hat{\theta_i} = \left\{ \mathbf{U}^{-1} + \frac{\mathbf{U}^{-1}\phi_i\phi_i^{\mathrm{T}}\mathbf{U}^{-1}}{\gamma_i} \right\} \left( \mathbf{\Phi}^{\mathrm{T}}\mathbf{y} - \phi_i y_i \right) = \left\{ \mathbf{U}^{-1} + \frac{\mathbf{U}^{-1}\phi_i\phi_i^{\mathrm{T}}\mathbf{U}^{-1}}{\gamma_i} \right\} \left( \sum_{j \neq i}^b y_j \phi_j \right)$$

一方で最終的な誤差 E は,

$$E = \frac{1}{n} \sum_{i}^{n} \left( \phi_i^{\mathrm{T}} \hat{\theta_i} - y_i \right)^2$$

$$\phi_{i}^{T}\hat{\theta}_{i} - y_{i} = \phi_{i}^{T} \left\{ \mathbf{U}^{-1} + \frac{\mathbf{U}^{-1}\phi_{i}\phi_{i}^{T}\mathbf{U}^{-1}}{\gamma_{i}} \right\} \left( \sum_{j \neq i}^{b} y_{j}\phi_{j} \right) - y_{i}$$

$$= \left\{ \phi_{i}^{T}\mathbf{U}^{-1} + \frac{\phi_{i}^{T}\mathbf{U}^{-1}\phi_{i}\phi_{i}^{T}\mathbf{U}^{-1}}{\gamma_{i}} \right\} \left( \sum_{j \neq i}^{b} y_{j}\phi_{j} \right) - y_{i}$$

$$= \left( 1 + \frac{1 - \gamma_{i}}{\gamma_{i}} \right) \phi_{i}^{T}\mathbf{U}^{-1} \left( \sum_{j \neq i}^{b} y_{j}\phi_{j} \right) - y_{i}$$

$$= \frac{1}{\gamma_{i}}\phi_{i}^{T}\mathbf{U}^{-1} \left( \sum_{j \neq i}^{b} y_{j}\phi_{j} \right) - y_{i}$$

$$= -\left( y_{i} - \sum_{j \neq i}^{b} y_{j} \frac{\phi_{i}^{T}\mathbf{U}^{-1}\phi_{j}}{\gamma_{i}} \right)$$

よって,

$$nE = \sum_{i}^{n} \left( y_i - \sum_{j \neq i}^{b} y_j \frac{\phi_i^{\mathrm{T}} \mathbf{U}^{-1} \phi_j}{\gamma_i} \right)^2$$

$$\mathbf{H} = \mathbf{I} - \mathbf{\Phi} \mathbf{U}^{-1} \mathbf{\Phi}^{\mathrm{T}} \qquad \tilde{H}_{ii} = 1 - \phi_i^{\mathrm{T}} \mathbf{U}^{-1} \phi_i = \gamma_i$$

であるので,

$$\tilde{\mathbf{H}}^{-1}\mathbf{H}\mathbf{y} = \begin{bmatrix} 1 & -\frac{\phi_1^{\mathrm{T}}\mathbf{U}^{-1}\phi_2}{\gamma_1} & -\frac{\phi_1^{\mathrm{T}}\mathbf{U}^{-1}\phi_3}{\gamma_1} & \dots & -\frac{\phi_1^{\mathrm{T}}\mathbf{U}^{-1}\phi_n}{\gamma_1} \\ -\frac{\phi_2^{\mathrm{T}}\mathbf{U}^{-1}\phi_1}{\gamma_2} & 1 & -\frac{\phi_2^{\mathrm{T}}\mathbf{U}^{-1}\phi_3}{\gamma_2} & \dots & -\frac{\phi_2^{\mathrm{T}}\mathbf{U}^{-1}\phi_n}{\gamma_2} \\ & & \cdot & & & \\ & & & \cdot & & \\ -\frac{\phi_n^{\mathrm{T}}\mathbf{U}^{-1}\phi_1}{\gamma_2} & \dots & \dots & \dots & 1 \end{bmatrix} \mathbf{y}$$

$$= \begin{bmatrix} y_1 - \sum_{j \neq 1}^b y_j \frac{\phi_1^{\mathrm{T}} \mathbf{U}^{-1} \phi_j}{\gamma_1} \\ y_2 - \sum_{j \neq 2}^b y_j \frac{\phi_2^{\mathrm{T}} \mathbf{U}^{-1} \phi_j}{\gamma_2} \\ & \cdot \\ \vdots \\ y_n - \sum_{j \neq n}^b y_j \frac{\phi_n^{\mathrm{T}} \mathbf{U}^{-1} \phi_j}{\gamma_n} \end{bmatrix}$$

以上から,

$$\|\tilde{\mathbf{H}}^{-1}\mathbf{H}\mathbf{y}\|^2 = \sum_{i}^{n} \left( y_i - \sum_{j \neq i}^{b} y_j \frac{\phi_i^{\mathrm{T}} \mathbf{U}^{-1} \phi_j}{\gamma_i} \right)^2 = nE$$