先端データ解析論 第9回レポート

電子情報学専攻 48-176403 石毛真修 2017 年 6 月 13 日

大問 1.

ガウスカーネルモデルを用いた、ラプラス正則化最小二乗確率的分類を実装する。まず、学習するデータを 生成する関数と、学習結果を等高線グラフとして描画する関数を定義する。

```
import numpy as np
from numpy.random import seed, randn

def create_data(n):
    points = np.linspace(0, np.pi, n // 2)
    u = - 10 * np.concatenate([np.cos(points) + 0.5, np.cos(points) - 0.5]).reshape(n, 1)    v = 10 * np.concatenate([np.sin(points), - np.sin(points)]).reshape(n, 1) + randn(n, 1)
    X = np.array([u, v]).reshape(2, n).transpose((1, 0))
    y = np.zeros((n, 1))
    y[0] = - 1
    y[-1] = 1
    return X, y

def draw_contour(axis_range=(-20, 20), granularity=100, z_func=lambda x, y: x + y):
    # You have to plt.show() after this function
    axis = np.linspace(*axis_range, granularity)
    X, Y = np.meshgrid(axis, axis)
    Z = z_func(X, Y)
    plt.contourf(X, Y, Z)
```

カーネル行列やカーネル関数を生成するのに必要な関数を定義する.

ラプラス行列を生成する関数を定義する.

パラーメタ θ を推定し、分類器を生成する。

以上をまとめて実行する.

```
def main():
    seed(42)
    X, y = create_data(200)
    labeled_X = X[(y != 0).reshape(-1)]
    unlabeled_X = X[(y == 0).reshape(-1)]
    labels = y[(y != 0).reshape(-1)]
    t = estimate_theta(labeled_X, labels, unlabeled_X, 4)
    classifier = generate_classifier(t, X)

    draw_contour(granularity=500, z_func=classifier)
    plt.plot(X[(y == 1).reshape(-1), 0], [X[(y == 1).reshape(-1), 1]], 'bo')
    plt.plot(X[(y == -1).reshape(-1), 0], [X[(y == -1).reshape(-1), 1]], 'rx')
    plt.plot(X[(y == 0).reshape(-1), 0], X[(y == 0).reshape(-1), 1], '.')
    main()
```

実行すると次のような結果を得る. 若干分類に失敗している部分が見受けられる.

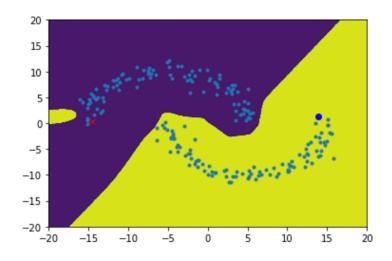


図 1: ラプラス正則化最小自乗分類による半教師あり学習の結果

大問 2

エネルギー距離の2乗の式

$$D_E^2(p_{\text{test}}, q_{\pi}) = 2\underbrace{\mathbb{E}_{\boldsymbol{x}' \sim p_{\text{test}}, \boldsymbol{x} \sim q_{\pi}} ||\boldsymbol{x}' - \boldsymbol{x}||}_{(1)} - \underbrace{\mathbb{E}_{\boldsymbol{x}', \tilde{\boldsymbol{x}}' \sim p_{\text{test}}} ||\boldsymbol{x}' - \tilde{\boldsymbol{x}}'||}_{(2)} - \underbrace{\mathbb{E}_{\boldsymbol{x}, \tilde{\boldsymbol{x}} \sim q_{\pi}} ||\boldsymbol{x} - \tilde{\boldsymbol{x}}||}_{(3)}$$

について, 各項を変形する.

$$\mathbb{E}_{\boldsymbol{x}' \sim p_{\text{test}}, \boldsymbol{x} \sim q_{\pi}} || \boldsymbol{x}' - \boldsymbol{x}| = \iint p_{\text{test}}(\boldsymbol{x}') q_{\pi}(\boldsymbol{x}) || \boldsymbol{x}' - \boldsymbol{x}| |d\boldsymbol{x}' d\boldsymbol{x}$$

$$= \iint p_{\text{test}}(\boldsymbol{x}') \left\{ \pi p_{\text{train}}(\boldsymbol{x}|y=1) + (1-\pi) p_{\text{train}}(\boldsymbol{x}|y=-1) \right\} || \boldsymbol{x}' - \boldsymbol{x}| |d\boldsymbol{x}' d\boldsymbol{x}$$

$$= \iint \left\{ \pi p_{\text{test}}(\boldsymbol{x}') p_{\text{train}}(\boldsymbol{x}|y=1) + (1-\pi) p_{\text{test}}(\boldsymbol{x}') p_{\text{train}}(\boldsymbol{x}|y=-1) \right\} || \boldsymbol{x}' - \boldsymbol{x}| |d\boldsymbol{x}' d\boldsymbol{x}$$

$$= \pi b_{+1} + (1-\pi) b_{-1}$$

$$= \pi (b_{+1} - b_{-1}) + b_{-1}$$

第2項はπを含まないので定数.

$$\begin{split} \mathbb{E}_{\boldsymbol{x},\tilde{\boldsymbol{x}}\sim q_{\pi}}||\boldsymbol{x}-\tilde{\boldsymbol{x}}|| &= \int \int q_{\pi}(\boldsymbol{x})q_{\pi}(\tilde{\boldsymbol{x}})||\boldsymbol{x}-\tilde{\boldsymbol{x}}||d\boldsymbol{x}d\tilde{\boldsymbol{x}} \\ &= \int \int \left\{\pi p_{\text{train}}(\boldsymbol{x}|y=1) + (1-\pi)p_{\text{train}}(\boldsymbol{x}|y=-1)\right\} \left\{\pi p_{\text{train}}(\tilde{\boldsymbol{x}}|y=1) + (1-\pi)p_{\text{train}}(\tilde{\boldsymbol{x}}|y=-1)\right\} \\ &\qquad \qquad \times ||\boldsymbol{x}-\tilde{\boldsymbol{x}}||d\boldsymbol{x}d\tilde{\boldsymbol{x}} \\ &= \int \int \left\{\pi^{2}p_{\text{train}}(\boldsymbol{x}|y=1)p_{\text{train}}(\tilde{\boldsymbol{x}}|y=1) + \pi(1-\pi)p_{\text{train}}(\boldsymbol{x}|y=1)p_{\text{train}}(\tilde{\boldsymbol{x}}|y=-1) \right. \\ &\qquad \qquad + \pi(1-\pi)p_{\text{train}}(\boldsymbol{x}|y=-1)p_{\text{train}}(\tilde{\boldsymbol{x}}|y=1) + (1-\pi)^{2}p_{\text{train}}(\boldsymbol{x}|y=-1)p_{\text{train}}(\tilde{\boldsymbol{x}}|y=-1)\right\} \\ &\qquad \qquad \times ||\boldsymbol{x}-\tilde{\boldsymbol{x}}||d\boldsymbol{x}d\tilde{\boldsymbol{x}} \\ &= \pi^{2}A_{+1,+1} + 2\pi(1-\pi)A_{+1,-1} + (1-\pi)^{2}A_{-1,-1} \\ &= \pi^{2}(A_{+1,+1} + A_{-1,-1} - 2A_{+1,-1}) + 2\pi(A_{+1,-1} - A_{-1,-1}) + A_{-1,-1} \end{split}$$

以上のから

$$J(\pi) = (2A_{+1,-1} - A_{+1,+1} - A_{-1,-1})\pi^2 - 2(A_{+1,-1} - A_{-1,-1} - b_{+1} + b_{-1})\pi + \text{constant}$$

大問 3.

線形モデルに対して、クラス比重み付き最小自乗法を実装する。 学習データとテストデータから、クラス比を推定するクラスを定義する。

```
import numpy as np
from numpy.random import seed , randn , RandomState
import matplotlib
from matplotlib import pyplot as plt
class ClassBalanceEstimater:
    def __init__(self , train_X , train_y , test_X ):
        self .X = train_X
        self .y = train_y
        self .test_X = test_X
        self ._pi = self ._calc_pi()
         @property
def train_X(self):
    return self._X
         @property
def train_y(self):
    return self._y
         @property
def test_X(self):
    return self._test_X
         @property
def data_num(self):
    return self._X.shape[1]
         def importance(self , label):
    if label == 1:
        return self._pi
    else:
        return 1 - self._pi
         def _tile_square(self, X, cols):
                    \begin{array}{lll} & & & & & & \\ & sq & = & np.\,square\left(X[0\,,\,\,:]\,\right) \,+\,np.\,square\left(X[1\,,\,\,:]\,\right) \\ & sq & = & sq.\,reshape\left(\left[X.\,shape\,[1]\,,\,\,1\right]\right) \\ & & return \,np.\,tile\left(sq\,,\,\,cols\,\right) \end{array} 
         def _dist_matrix(self, X0, X1):
                  X: [[x0[0], x1[0], \dots], [x0[1], x1[1], \dots]]
Returns: [[||X0_0 - X1_0||, ||X0_0 - X1_1||, \dots], \dots]
                   """
X0_sq = self._tile_square(X0, X1.shape[1])
X1_sq = self._tile_square(X1, X0.shape[1])
return np.sqrt(X0_sq + X1_sq.T - 2 * X0.T @ X1)
         def _A(self, y0, y1):
    X0 = self..X[:, self..y == y0]
    X1 = self..X[:, self..y == y1]
    n0 = X0.shape[1]
    n1 = X1.shape[1]
    return np.sum(self._dist_matrix(X0, X1)) / (n0 * n1)
         def _b(self , y):
    X = self ..X[: , self .-y == y]
    n = X.shape[1]
    n_test = self ..test_X .shape[1]
    return np.sum(self ._dist_matrix(self ._test_X , X)) / (n * n_test)
```

上記のクラスを受け取り、SVM による線形分離を行うクラスを定義する.

```
class LineSeparator:
    def __init__(self, data, learning_rate=0.00001, regularize=100.):
    """"
               X: \ [[x0[0], x1[0], \dots], [x0[1], x1[1], \dots]] \ y: \ [y0, y1, \dots]
               self._data = data
               self._thetas = np.zeros(self._data.data_num)
self._bias = 0
self._learning_rate = learning_rate
self._lambda = regularize
       def train(self, compensate_class_balance=False, epochs=150):
    for epoch in range(epochs):
      # Show log
      if epoch % 200 == 0:
            self.-pretty_print(epoch, self.omega)
                      # Updata thetas
new_thetas = np.copy(self._thetas)
for k, _ in enumerate(self._thetas):
    update = 0
    for j in range(self._data.data_num):
        update += self._subdiff.theta(j, k, compensate_class_balance)
    new_thetas[k] -= self._learning_rate * update
new_thetas -= self._learning_rate * self._lambda * self._data.train_X.T @ self._data.train_X @ self._thetas
self._thetas = new_thetas
                       # Updata b
for j in range(self._data.data_num):
    self._bias -= self._learning_rate * self._subdiff_b(j, compensate_class_balance)
               w = self.omega
self._pretty_print(None, w, bias=self._bias)
return w, self._bias
        @property
def omega(self):
               omega = sum theta_j psi(x_j)
               return self._data.train_X @ self._thetas
        @property
def b(self):
    return self._bias
        def -pretty-print(self, epoch, omegas, bias=None):
    if epoch is None:
        log = "Finally:\n"
               else:
    log = "Epoch %d:\n" % epoch
               if bias is not None:
log += "b: %f\n" % bias
               print(log)
        \mathbf{def} _f(self, x):
               x: [x[0], x[1]]

Returns: f_theta(x) = w x + b
               return x.T @ self._data.train_X @ self._thetas + self._bias
        \mathbf{def} \ \mathtt{\_subdiff\_theta} \ (\ \mathtt{self} \ , \ \ \mathtt{i} \ , \ \ \mathtt{k} \ , \ \ \mathtt{compensate\_class\_balance=False} \ ) :
               i-th subdifferentiation by k_-th theta
               if 1 - self._data.train_y[i] * self._f(self._data.train_X[:, i]) > 0:
    if compensate_class_balance:
        return - self._data.train_y[i] * self._data.train_X[:, k] @ self._data.train_X[:, i] * self._data.importancelse:
    return - self._data.train_y[i] * self._data.train_X[:, k] @ self._data.train_X[:, i]
               else:
       \mathbf{def} \  \  \text{-subdiff-b} \ (\ \text{self} \ , \ \ i \ , \ \ \text{compensate-class-balance=False} \ ) :
               i-th subdifferentiate by b
                       - self._data.train_y[i] * self._f(self._data.train_X[:, i]) > 0:
if compensate_class_balance:
    return - self._data.train_y[i] * self._data.importance(self._data.train_y[i])
                      else:
return - self._data.train_y[i]
               else:
return 0
```

以上をまとめて実行する.

実行すると次のような結果を得る.

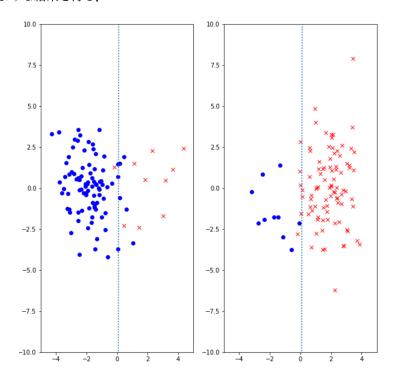


図 2: クラス比重み付き分類の結果

学習データのみを見ると、もう少し右側に境界を置くのが適切であるように見えるが、テストデータをみるとこの位置に配置する方が良いことがわかる.